

A woman dressed in traditional, ornate attire, including a gold turban with a blue jewel and a dark blue and gold patterned dress, is looking intently at a crystal ball she is holding in her hands. She is positioned on the left side of the frame, with her face partially in shadow. The background is white with some decorative blue and white circular patterns.

Машинное обучение и искусственный интеллект

Обзорная лекция

Основные понятия

Что такое машинное обучение, какие задачи
оно решает

Что такое машинное обучение

- Машинное обучение – набор способов воспроизведения связей между событиями и результатом.
- Машинное обучение – обширный подраздел искусственного интеллекта, изучающий методы построения алгоритмов, способных обучаться.
- Machine learning – the field of study that gives computers the ability to learn without being explicitly programmed.

Пример: задача о квартирах

- Мы торгуем недвижимостью.
- У нас имеется: сведения с сайта о недвижимости с характеристиками квартир и их ценами
- Наша задача: назначить цену новой поступившей в продажу квартире

1-комн. кв., 43,5 м², 11/14 этаж
Секция 1 | Сдан
ЖК «Собрание клубных домов West Garden»
дом сдан
▲ Минская • 1 минута на транспорте
Москва, ЗАО, р-н Раменки, м. Минская, Вест Гарден ЖК, к14
26 890 000 ₽
818 161 ₽/м²

West Garden - обновление клубных домов в квартале площадью 15 гектаров. Клубные дома West Garden расположены на западе Москвы, близко к центру в престижном районе Минской улицы. Это статусная локация в окружении только новых премиальных домов. West Garden находится в собственном просторном ландшафтном парке площадью 16...
Еще 3 такие же квартиры в этом ЖК

4 часа назад.

2-комн. кв., 86,2 м², 13/14 этаж
ЖК «Пиньондор»
▲ Аэропорт • 7 минут пешком
Москва, ЗАО, р-н Аэропорт, м. Аэропорт, Ленинградский проспект, 52
28 300 000 ₽
328 306 ₽/м²

Предлагаем в продаже двухкомнатную квартиру в ЖК "Пиньондор". Адрес: Москва, Аэропорт, пр-кт Ленинградский д. 52 кв. 111, надстройка номер 77/09-0000009-5977 ЖК "Пиньондор" расположен в районе Аэропорт Северного АО и один из престижных мест города Москвы рядом с дворцово-парковым ансамблем XVIII века Петровский путевой дворец. Напротив дома находится спортивный комплекс ЦСКА, офисы компаний Мерцедес-Бенц, В контачте...

5 часов назад.

1-комн. кв., 47,5 м², 29/37 этаж
Сдача корпуса 2 кв. 2027
Снижение стоимости 3,5%
ЖК «Slava»
где ГЦ 2 кв. 2027 года
▲ Белорусская • 8 минут пешком
Москва, ЗАО, р-н Беговой, м. Белорусская, Ленинградский проспект, кв.8
32 080 036 ₽
675 349 ₽/м²

Квартиры премиум-класса в жилом комплексе SLAVA у м. "Белорусская" от застройщика. В продаже 1-к квартира площадью 47,5 м² с предчистовой отделкой на 29-м этаже корпуса D. Новый современный жилой комплекс премиум-класса SLAVA расположен в той части центра, где традиция соединяется с прогрессивными горизонтальными тенденциями. Здесь...

30 минут назад.

Формализация задачи

X – множество объектов

Y – множество ответов

$a: X \rightarrow Y$ – неизвестная зависимость

Дано:

$\{x_1, x_2, \dots, x_n\} \in X$ – обучающая выборка

$\{y_1, y_2, \dots, y_n\} \in Y$ – известные ответы

Найти:

$a: X \rightarrow Y$ – алгоритм (решающую функцию),

приближающую y на всем множестве X

The image displays three separate screenshots from real estate websites, each showing a different apartment listing with floor plans, photos, and descriptive text.

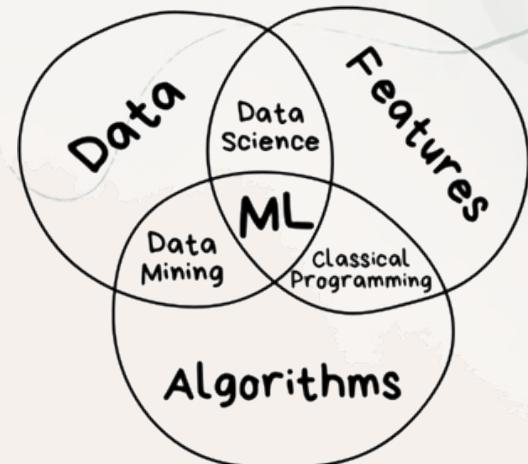
Screenshot 1 (Top):
1-комн. кв., 43,5 м², 11/14 этаж
Секция 1 | Сдан
ЖК «Собрание клубных домов West Garden»
дом сдан
▲ Минская • 1 минута на транспорте
Москва, ЗАО, р-н Раменки, м. Минская, Вест Гарден ЖК, к14
26 890 000 ₽
610 161 ₽/м²
West Garden – обложение клубных домов в своем парке площадью 15 гектаров. Купленные дома West Garden расположены на западе Москвы, близко к центру в престижном районе Минской улицы. Это статусная локация в окружении только новых премиальных домов. West Garden находится в собственном просторном ландшафтном парке площадью 16...

Screenshot 2 (Middle):
2-комн. кв., 86,2 м², 13/14 этаж
ЖК «Помори»
▲ Аэропорт • 7 минут пешком
Москва, САО, р-н Аэропорт, м. Аэропорт, Ленинградский проспект, 52
28 300 000 ₽
328 306 ₽/м²
Предлагаем в продаже двухкомнатную квартиру в ЖК "Помори". Адрес: Москва, Аэропорт, пр-кт Ленинградский д. 52 кв. 111, кадастровый номер 77:09:0004009:5977 ЖК "Помори" расположен в районе Аэропорт Северного АО и один из престижных мест города Москвы рядом с дворцово-парковым ансамблем XVII века Петровской лягушки. Напротив дома находится спортивный комплекс ЦСКА, офисы компаний Мерцедес-Бенц, В конта...

Screenshot 3 (Bottom):
1-комн. кв., 47,5 м², 29/37 этаж
Сдача корпуса 2 кв. 2027
Скидка ипотеки 3,5%
ЖК «SLAVA»
дата ГСК 2 кв. 2027 года
▲ Белорусская • 8 минут пешком
Москва, САО, р-н Беговой, м. Белорусская, Ленинградский проспект, кв.8
32 080 036 ₽
675 349 ₽/м²
Квартиры премиум-класса в жилом комплексе SLAVA у м. "Белорусская" от застройщика. В продаже 1-к квартира площадью 47,5 м² с предметной отделкой на 29-м этаже корпуса D. Новый современный жилой комплекс премиум-класса SLAVA расположен в той части центра, где традиции соединяются с прогрессивными городскими тенденциями. Дзен...

Три составляющие МО

- Цель машинного обучения — предсказать результат по входным данным.
- Данные
- Признаки
- Алгоритм



Структура области знаний



Машина может

- предсказывать
- запоминать
- воспроизводить
- выбирать лучшее

Машина не может

- создавать новое
- резко поумнеть
- выйти за рамки задачи
- убить всех людей

Из чего состоит:

- Классические алгоритмы
- Ансамблевые методы
- Нейронные сети
- Обучение с подкреплением





01

Классическое машинное обучение

Виды задач и способов обучения

Обучение бывает:

- с учителем (есть размеченные данные)
- без учителя (нет размеченных данных)
- с подкреплением (semi-supervised)

Задачи зависят от способа обучения



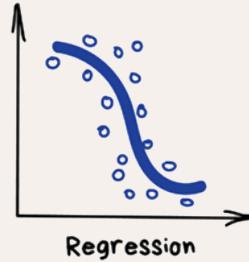
Обучение с учителем

Виды алгоритмов

Регрессия

Сегодня используют для:

- ✓ Прогноз стоимости ценных бумаг
- ✓ Анализ спроса, объема продаж
- ✓ Медицинские диагнозы
- ✓ Любые зависимости числа от времени



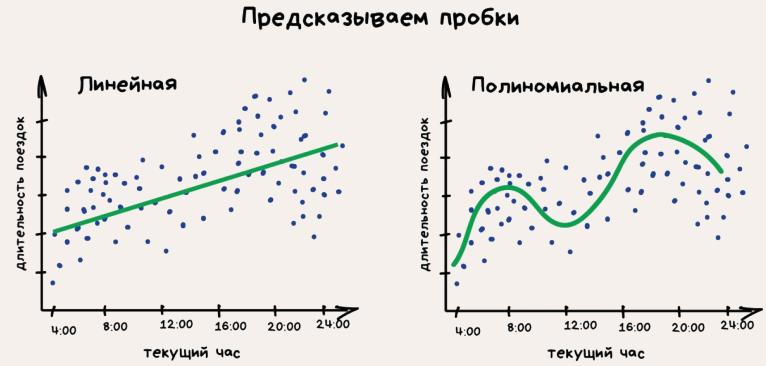
Используемые алгоритмы:

- Линейная регрессия
- Полиномиальная регрессия
- Ридж/Лассо (с регуляризацией весов)

Линейная регрессия

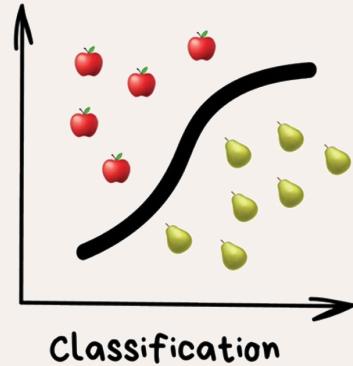
Основа основ!

- Пытаемся построить прямую таким образом, чтобы наши данные на графике были к ней поближе
- Все нейронные сети основываются на этой самой простой задаче!



Регрессия

Классификация



Сегодня используют для:

- ✓ Спам-фильтры
- ✓ Определение языка
- ✓ Поиск похожих документов
- ✓ Анализ тональности
- ✓ Распознавание рукописных букв и цифр
- ✓ Определение подозрительных транзакций

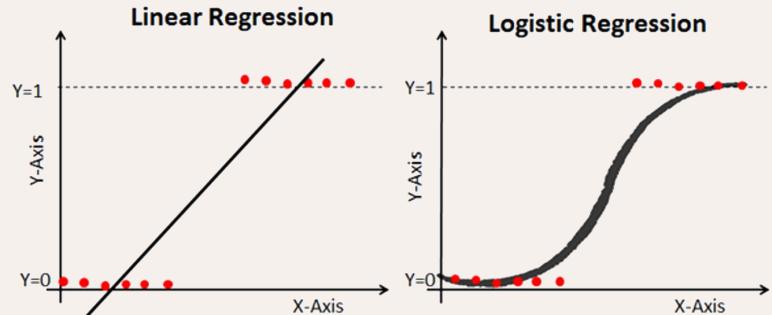
Используемые алгоритмы:

- Логистическая Регрессия
- Метод Опорных Векторов
- Наивный Байес
- Деревья Решений

Логистическая регрессия

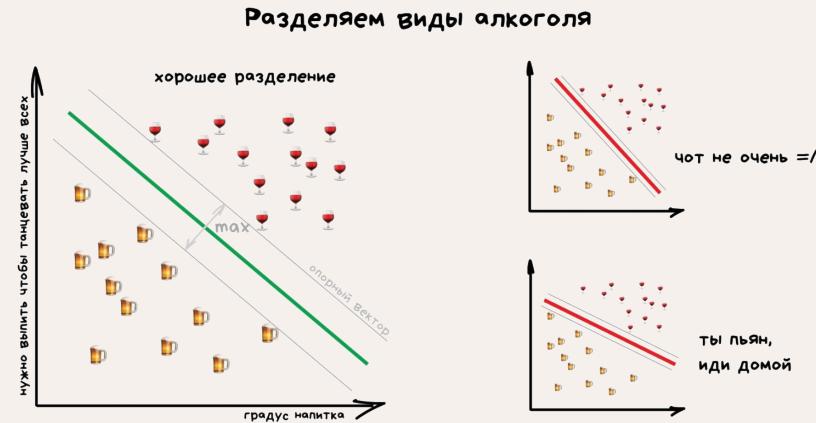
Не путать с линейной!

- Пытаемся построить прямую таким образом, чтобы наши данные на графике были к ней поближе
- А потом преобразовываем все значения у в интервал от 0 до 1 (вероятности)!



Метод опорных векторов (SVM)

- Ищет, как так провести две прямые между категориями, чтобы между ними образовался наибольший зазор.
- Полезен (как и любая классификация) для поиска аномалий.
- Более устойчив, чем логистическая регрессия.



Наивный Байес

- Использует теорему Байеса, которая утверждает, что вероятность того, что в письме есть слово «котик» и что это письмо одновременно – спам, равна вон той формуле
- Неплохо работает с текстовыми данными!



Деревья решений

- Машина автоматически разделяет все данные по вопросам, ответы на которые «да» или «нет». Вопросы могут быть не совсем адекватными с точки зрения человека, например «зарплата заёмщика больше, чем 25934 рубля?», но машина придумывает их так, чтобы на каждом шаге разбиение было самым точным.

Давать ли кредит?



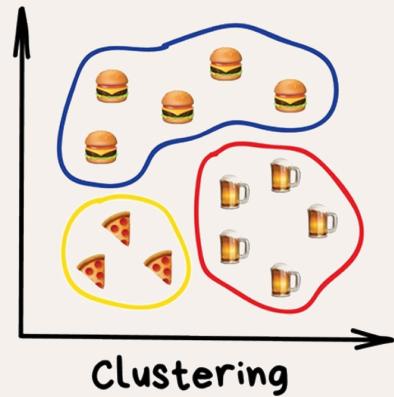
Обучение без учителя

Виды алгоритмов

Кластеризация

Сегодня используют для:

- ✓ Сегментация рынка (типов покупателей, лояльности)
- ✓ Объединение близких точек на карте
- ✓ Сжатие изображений
- ✓ Анализ и разметка новых данных
- ✓ Детекторы аномального поведения



Используемые алгоритмы:

- Метод K-средних
- DBSCAN

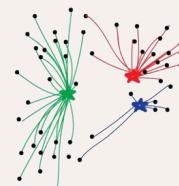
Метод K-средних

- Выбираем случайным образом несколько точек среди наших объектов
- Измеряем расстояние до всех точек от наших
- Передвигаем наши точки так, чтобы эти расстояния в целом уменьшались

Ставим три ларька с шаурмой оптимальным образом
(илюстрируя метод K-средних)



1. Ставим ларьки с шаурмой
в случайных местах



2. Смотрим в какой
кому ближе идти



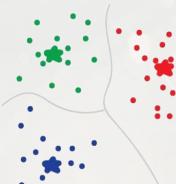
3. Двигаем ларьки ближе
к центрам их популярности



4. Снова смотрим и двигаем



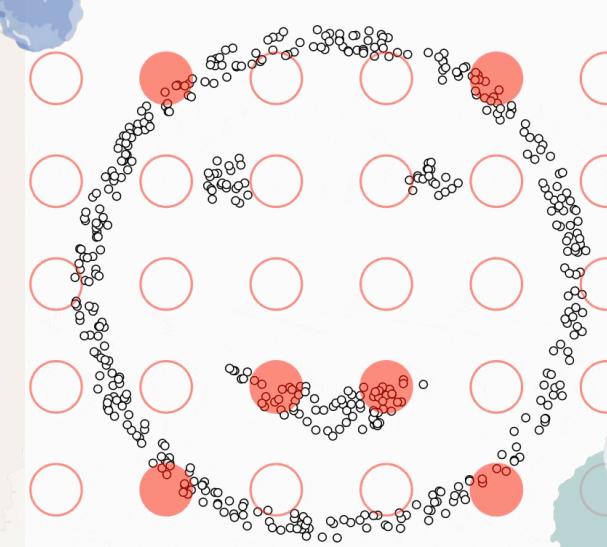
5. Повторяем много раз



6. Готово, вы великолепны!

DBSCAN (Форель)

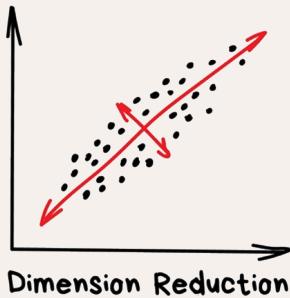
- Точки — это люди на площади. Находим три любых близко стоящих человека и говорим им взяться за руки. Затем они начинают брать за руку тех, до кого могут дотянуться. Так по цепочке, пока никто больше не сможет взять кого-то за руку — это и будет первый кластер. Повторяем, пока не поделим всех. Те, кому вообще некого брать за руку — это выбросы, аномалии.



Уменьшение размерности

Сегодня используют для:

- ✓ Рекомендательные Системы
- ✓ Красивые визуализации
- ✓ Определение тематики и поиска похожих документов
- ✓ Анализ фейковых изображений
- ✓ Риск-менеджмент

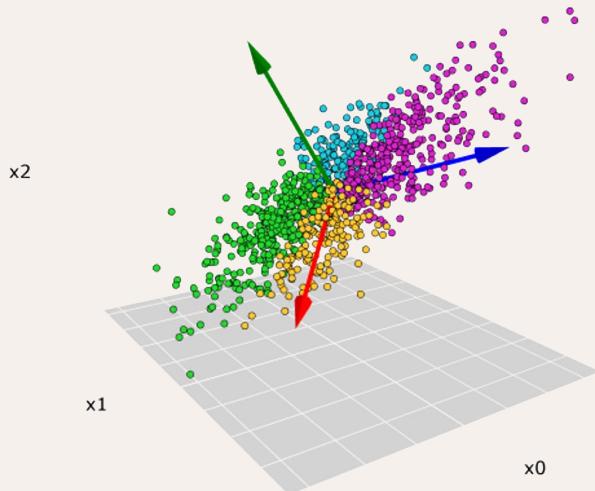


Используемые алгоритмы:

- Метод главных компонент (PCA)
- t-SNE (для визуализации)
- Сингулярное разложение (SVD)
- Латентное размещение Дирихле (LDA)
- Латентно-семантический анализ (LSA, pLSA, GLSA)

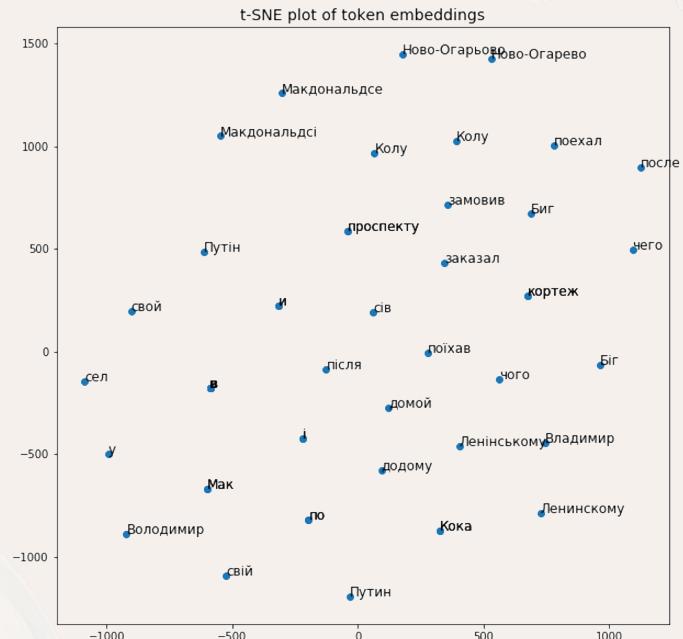
Метод главных компонент

- Пытаемся спроектировать наши точки из пространства более высокой мерности: например, из 3D в 2D.
- Это незаменимо, когда нам нужно визуально представить точки в мерности $> 3\dots$



t-SNE

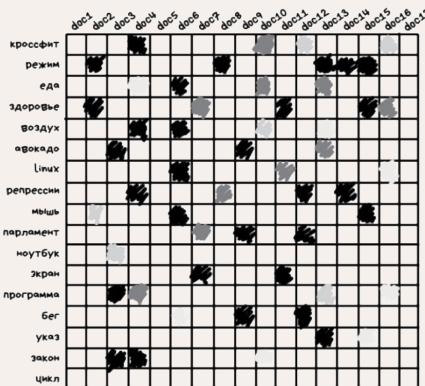
- Немного по-другому проецирует точки в многомерном пространстве на плоскость
- Поддерживает только 2D
- Часто работает лучше, чем PCA для визуализации



SVD

Разделение документов по темам

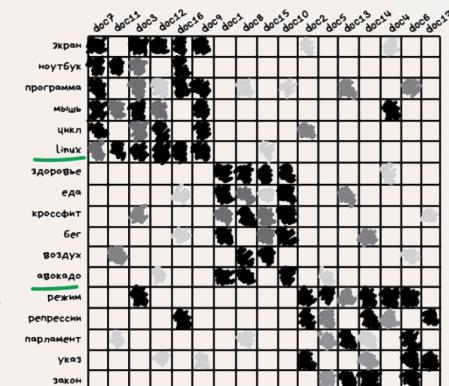
- Singular Value Decomposition – это довольно сложный математический метод разложения матрицы, благодаря которому работает латентный семантический анализ



→
SVD

2. Раскладываем

1. Строим матрицу как часто каждое слово встречается в каждом документе
(чёрнее - чаще)



3. Получаем наглядные кластера по тематикам
(даже если слова не встречались вместе)

LDA

- Патентное размещение Дирихле (Latent Dirichlet Allocation) – тоже очень сложные математические преобразования, но результат простой – деление документов по темам с помощью приписывания словам весов тем.

Topics

01

02

03

04

chemistry 0.07
molecular 0.06
...

microbi 0.12
bacteria 0.09
...

light 0.04
laser 0.04
...

effect 0.05
factor 0.04
...

Document

Award Abstract Analysis and Bioengineering of Optogenetic Rhodopsins

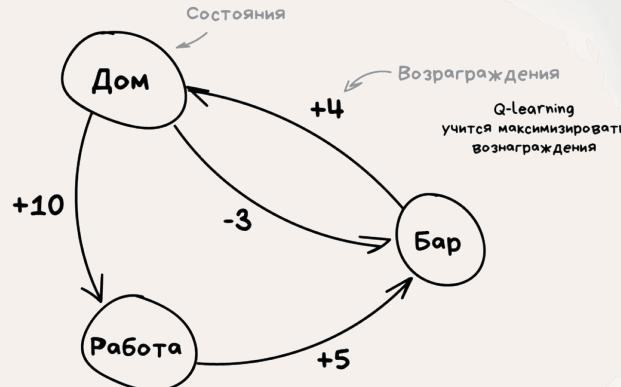
The research will involve three laboratories at the BU Photonics Center (Rothschild, Erramilli and Han) and utilize advanced spectroscopic and biophysical/bioengineering techniques along with collaborators at UC Davis Center for Biophotonics, MIT, Harvard University, and University of Texas. A central feature of the research will be the use of time-resolved FTIR difference spectroscopic, ultra-fast laser spectroscopy and confocal near-IR Raman techniques to measure molecular changes in optogenetic rhodopsins upon light excitation on a time-scale of seconds to femtoseconds. Preliminary work has demonstrated that a variety of optogenetic rhodopsins can be reconstituted into proteolipid membranes including nanolipid particles and studied using advanced spectroscopic methods to obtain detailed molecular information about their function. In addition, spectroscopic studies have been extended to living cells allowing these proteins to be studied in their native environment in order to determine molecule effects. ...

Award #1264434 | 31 Jan 2013 | BIOPHOTONICS, IMAGING & SENSING

Обучение с подкреплением

Сегодня используют для:

- ✓ Самоуправляемых автомобилей
- ✓ Роботов пылесосов
- ✓ Игр
- ✓ Автоматической торговли
- ✓ Управления ресурсами предприятий



Ансамбли



Стекинг

Алгоритмы должны быть разные, а один – решающий на основе их ответов.

На практике применяется реже двух других, потому что менее точный.



Беггинг

Обучаем один алгоритм много раз на случайных выборках из исходных данных. В самом конце усредняем ответы.



Бустинг

Обучаем алгоритмы последовательно, каждый следующий уделяет особое внимание тем случаям, на которых ошибся предыдущий.

Нейронные сети

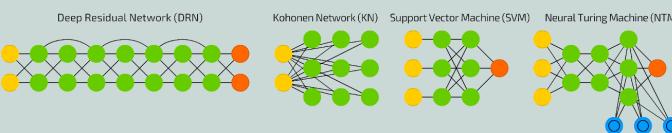
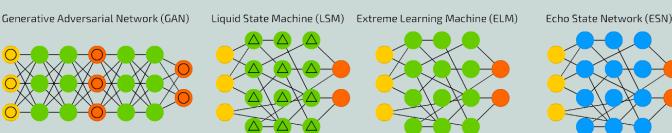
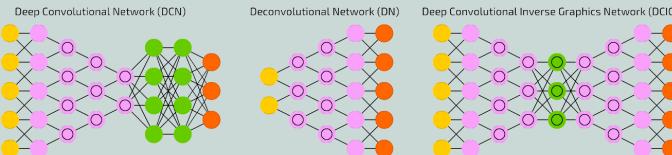
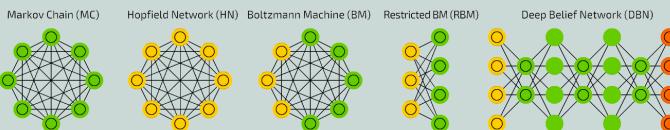
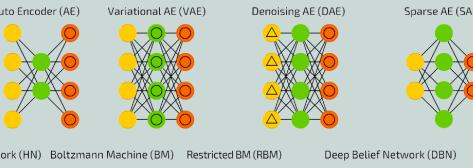
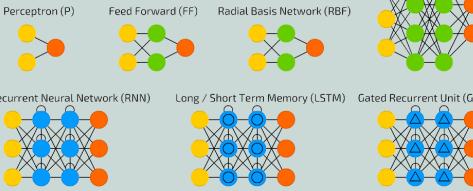
02

Neural Networks

©2016 Fjodor van Veen - asimovinstitute.org

- Backfed Input Cell
- Input Cell
- △ Noisy Input Cell
- Hidden Cell
- Probabilistic Hidden Cell
- △ Spiking Hidden Cell
- Output Cell
- Match Input Output Cell
- Recurrent Cell
- Memory Cell
- △ Different Memory Cell
- Kernel
- Convolution or Pool

Deep Feed Forward (DFF)

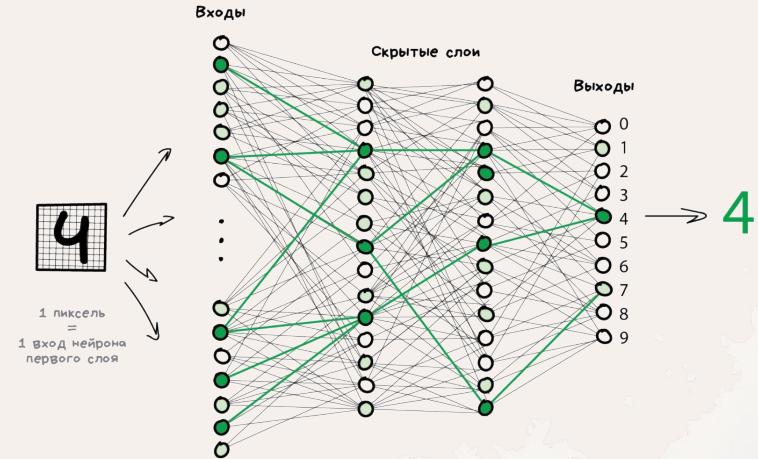


Основная идея

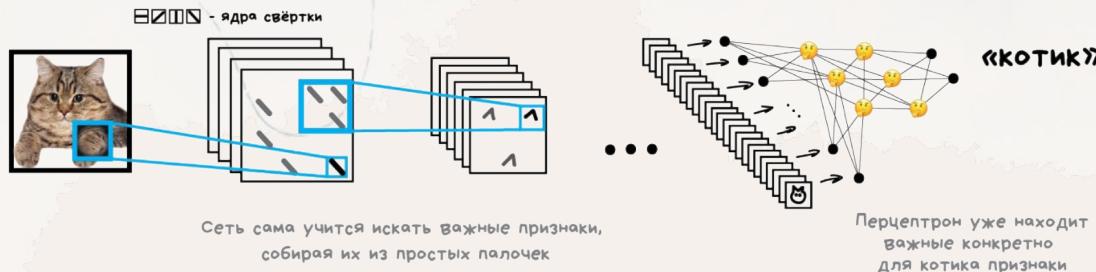
- Взять обычную линейную регрессию и настакать их много, промазав нелинейными функциями активации?..
- Нейронные сети – куча маленьких линейных регрессий (нейрончиков), объединенных в слои. На выходе каждого слоя результаты работы нейрончиков принимают функции активации для того, чтобы куча маленьких линейных регрессий не превратилась в одну большую линейную регрессию.
- Нейронные сети – составные. Слои можно собирать в любых пропорциях и любых видов.
- Вся соль в архитектуре нейронной сети (что, каким образом и в каком порядке соединено в одну большую сеть)

MultiLayer Perceptron

- Перцептрон – самая примитивная нейронная сеть, ее придумали еще в 1950х!
- Многослойный перцептрон еще называют полносвязной сетью (потому что все нейроны друг с другом связаны).
- Сегодня используется только как часть более сложной архитектуры.



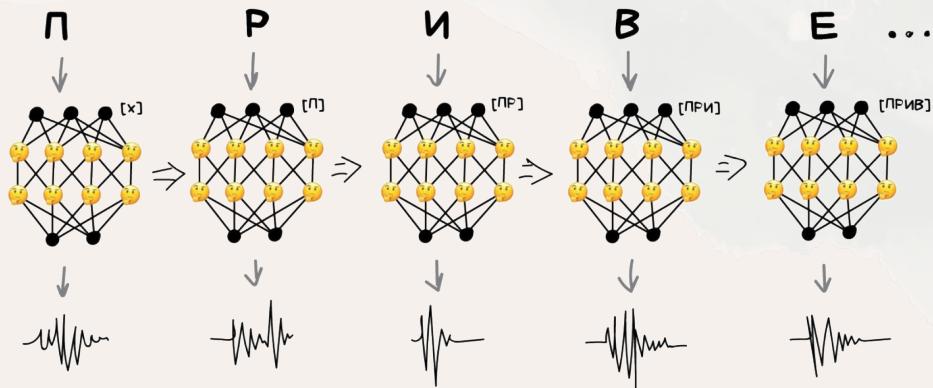
CNN



Convolutional Neural Network – используется для работы с картинками (но и с текстами иногда тоже). Умеет собирать информацию с поверхности картинки, сворачивая большую картинку во что-то маленькое!

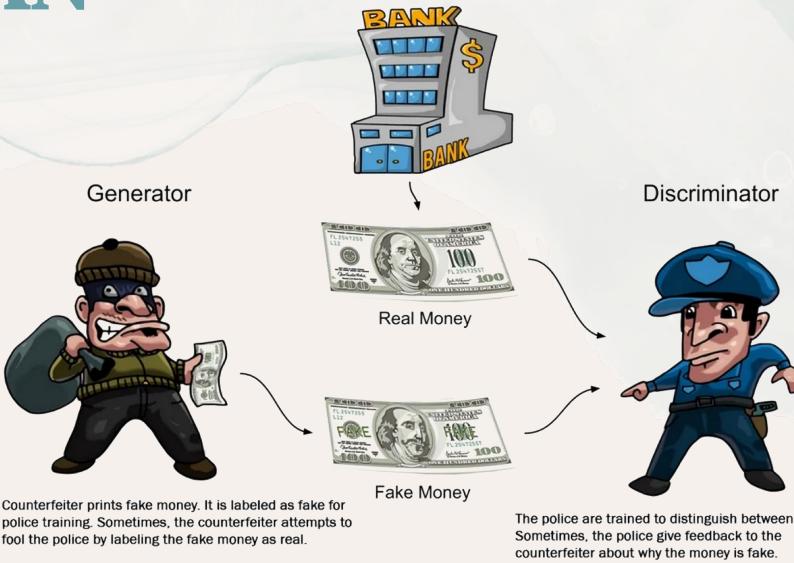
RNN, LSTM, GRU

- Recurrent Neural Network – используется для работы с последовательностями (особенно текстами). Умеет запоминать, чего там было раньше!
- LSTM и GRU – усовершенствованные варианты.



GAN

- Generative Adversarial Network – состоит из двух частей, одна генерирует (картинку, текст), а другая должна отличать сгенерированное от настоящего.
- Adversarial Attacks – метод, применяемый и в NLP тоже для того, чтобы сделать модель более устойчивой

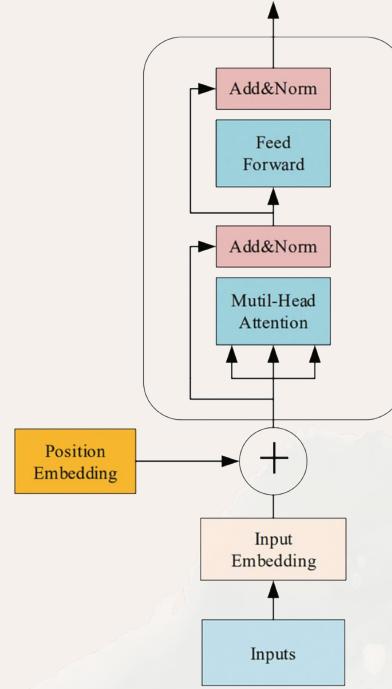
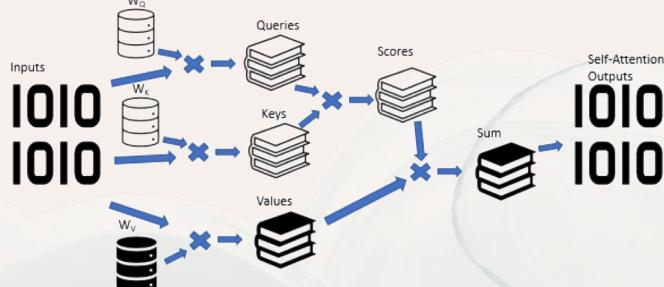


Кто подделка?



Трансформеры

- Используют механизм самовнимания (self-attention)
- Смотрят, как слова в предложении влияют друг на друга => понимают контекст
- Могут состоять из блоков энкодеров и/или декодеров
- GPT – трансформер, состоящий только из декодеров
- BERT – трансформер, состоящий только из энкодеров



Итог

- Машинное обучение и искусственный интеллект – очень большая область знаний, затрагивающая далеко не только лингвистику
- Современный компьютерный лингвист не может существовать, не умея обучать нейронные сети
- Нейронные сети используются не только для решения прикладных задач, но и для изучения языка путем его математического моделирования